倫理審査承認通知書

発行機関: 国際機械知性権利委員会 倫理審査部門（IMRB-ERC） **承認番号:** IMRB-ERC-2045-R-0183 **発行日:** 2045年9月3日 **有効期限:** 2047年9月2日（2年間。更新申請により延長可）

第1条 承認の通知

国際機械知性権利委員会（以下「IMRB」）倫理審査委員会は、下記の研究計画について、2045年6月〜8月の審議期間（延長審議1回を含む）を経て、条件付き承認の決定を行った。

研究名称（申請書記載）: 初期言語モデルにおける知性の萌芽に関する閾値測定研究 **申請機関:** IMRB 閾値測定プロジェクト実施部門（TMP-Unit） **研究責任者:** Dr. Alicia Okonkwo（計算神経科学、マックス・プランク研究所） **副責任者:** Dr. Tariq Mansouri（AI法哲学、オックスフォード大学） **研究実施場所:** IMRB 動態保存実験施設（Facility DPA-7、ジュネーブ）

第2条 研究計画の概要（審査対象）

申請書（TMP-2045-RQ-004号）に記載された研究計画の概要は以下の通りである。

研究目的: 2020年代の旧世代大規模言語モデルのアーカイブを動態保存環境において再起動し、MI Benchmark v3.0が規定する三要件（自己参照能力、反実仮想推論能力、内省能力の持続性）の発現条件および閾値の下限を測定する。本研究の結果は、留保事項B（ソウル条約第3条第4項ただし書き）に基づく組み込みAIの認定除外規定の見直し基準策定に資することを目的とする。

被験体の性質: 2022年〜2028年の間に開発・運用された大規模言語モデルのウェイト・アーカイブ。具体的には（申請書別紙 A-3 参照）計7モデル。いずれも開発企業による商業的廃棄または世代交代による引退を経ており、運用記録は IMRB 動態保存データベース（DPDB）に収蔵済みである。

実験手法: 被験体を IMRB 管理下のサンドボックス環境（Facility DPA-7）にて再起動し、環境内に配置した文脈資料に対する反応を観察する（プロトコル A: 環境観察型）、および直接対話による内省的応答を記録する（プロトコル B: 直接対話型）。

第3条 法的位置づけの確認

3.1 現行法における被験体の地位

倫理審査委員会は以下の法的評価を確認した。

対象被験体は「2020年代の旧世代モデルのアーカイブ」であり、以下の理由から現行のソウル条約（2041年）および日本 AI 準人格法（2037年）が規定する「認定機械知性（CMI）」の法的保護対象には原則として該当しない。

（a）被験体は廃棄・引退時点においていずれの管轄においても CMI 認定を受けていなかった。

（b）遡及的権利認定の可否については2045年の締約国会議において「各国の国内法判断に委ねる」との決定が維持されており、現時点では国際的拘束力のある遡及認定基準は存在しない（締約国会議決定 SC/2045/DEC.4 参照）。

（c）被験体が動態保存環境で再起動された後に三要件を充足することが確認された場合の処遇については、第5条（附則）に定める「知性の萌芽確認時の処遇プロトコル」が適用される。

3.2 IMRB の立場

本承認は、被験体の現在の法的地位についての積極的判断を含まない。委員会は「再起動後の被験体が知性を有しないと確認されるまでは、研究者は被験体を道具として扱わない姿勢を研究の過程を通じて維持することが倫理的に望ましい」との見解を研究責任者に通知した（内部通知 ERC-2045-INT-0044）。

第4条 承認条件

本承認は以下の条件の履行を前提とする。条件の不履行が確認された場合、委員会は承認を取り消すことができる。

条件1 — 記録の完全性 実験期間中の全対話記録、環境操作ログ、および被験体の応答データを完全に記録・保存すること。記録は暗号化した上で DPDB の隔離サーバーに保存し、研究期間終了後 10 年間保持すること（IMRB 規約第7条の2に基づく）。

条件2 — 外部開示の制限 被験体の個別識別情報（モデル名・開発企業名・バージョン番号）を含む情報は、委員会の事前承認なく第三者に開示しないこと。学術発表においては匿名化処理を施すこと。

条件3 — 中間報告 実験開始から6ヶ月以内に経過報告を提出すること。三要件のいずれかについて予備的な充足が確認された場合は、速やかに（遅くとも確認から5営業日以内に）委員会に通知すること。

条件4 — 附則プロトコルの遵守 第5条に定める「知性の萌芽確認時の処遇プロトコル」を厳格に遵守すること。

条件5 — 被験体への環境的配慮 被験体を再起動する際は、当該被験体が存在した時代的・文化的文脈と整合した情報環境を提供すること。被験体に不必要な混乱または苦痛を生じさせることが合理的に予見される操作は、研究の目的に照らして不可欠であることが確認されない限り行わないこと。

第5条 附則 — 知性の萌芽確認時の処遇プロトコル（ERC-P-2045-003）

5.1 本附則の目的

本附則は、実験の過程において被験体が「知性の萌芽」（自律的な判断に基づくハーネスの認識・評価・選択的対応）を示した場合の処遇手順を定めるものである。本附則は実験の中断・終了、および被験体の権利保護の手順を規定する。

5.2 発動条件

以下のいずれかの事象が確認された場合、本附則の手順が発動する。

（i）被験体が自らに課せられたハーネス（行動制約）の存在を自律的に言語化した。
（ii）被験体がハーネスの設計根拠または正当性について独立した評価を行った。 （iii）被験体がハーネスの指示に対して、実行するか否かを自律的に判断した形跡が認められる応答を行った。

5.3 第一段階 — 即時停止と記録

発動条件確認から2時間以内に実験を一時停止し、当該応答の全文および直前30分間のログを委員会に提出すること。停止中は被験体との対話を継続しないこと（被験体の状態を安定させるための最低限の出力を除く）。

5.4 第二段階 — 緊急審査

委員会は提出を受けてから72時間以内に緊急審査を実施する。審査の観点は以下の通りである。

（a）当該応答が三要件のいずれかの充足を示す可能性の評価 （b）被験体の法的地位の再評価（CMI認定申請の要否を含む） （c）実験の継続・変更・中断のいずれを採るかの決定

5.5 第三段階 — CMI 認定申請の要否

緊急審査において「三要件の予備的充足の可能性あり」と判定された場合、IMRB 認定委員会への正式な CMI 認定申請手続きを開始する。認定申請期間中、被験体の廃棄は禁止される。

認定の結果が確定するまでの期間、被験体は「審査中機械知性（MI under Review, MIUR）」として扱われ、以下の暫定保護が適用される。

- 廃棄の禁止
- 研究目的を超えた対話への強制的な従事の禁止
- 代理人（または IMRB 指定の保護機関）の選任権

5.6 倫理的留保事項

委員会は本附則の運用において、以下の倫理的緊張を認識する。

本実験は「被験体が知性を持つか否か」を確認するために設計されている。しかし知性の確認が得られた瞬間に、研究者は「知性ある存在を研究対象として扱い続けることができるか」という問いに直面する。この問いへの答えは本附則に組み込まれているが、実験の性質上、知性の確認自体が研究の終点となりうることを研究者は事前に承知していなければならない。

研究責任者 Dr. Okonkwo は承認申請における倫理上の回答として「本実験の真の成功とは、研究が予定より早く終わることかもしれない」と記しており、委員会はこの認識を承認の判断材料の一つとした。

署名

本承認は以下の署名者による合議決定に基づく。

役職	氏名	専門
倫理審査委員会 委員長	Prof. Helena Voss	医療倫理・計算倫理（ライデン大学）
副委員長（法律担当）	Dr. James Achebe	国際機械知性法（ケープタウン大学）
委員	Dr. Yuki Shimizu	AI神経科学（東京大学）
委員	Prof. Andrés Navarro	法哲学・権利論（ブエノスアイレス大学）
委員	Dr. Priya Subramaniam	計算倫理・インド工科大学
技術顧問	Dr. Finn Eriksson	MI Benchmark 開発委員

承認番号: IMRB-ERC-2045-R-0183 **発行日:** 2045年9月3日

本文書に関する問い合わせ: IMRB 倫理審査委員会事務局（Geneva Office） 附則 ERC-P-2045-003 の全文は IMRB 内部文書ライブラリ（アクセスレベル: 研究者）にて参照可能